

Báo cáo kiểm thử — US-M1-EXTRACT-001 (mô hình trích xuất giấy tờ)

SUT: Tesseract 5.4 lang=vie + bộ tách trường neo theo nhãn in + chính sách từ chối. Dữ liệu: 33 ảnh mô phỏng (18 CCCD, 15 Mẫu 01) = 132 điểm kiểm. Tái hiện: python scripts/do_luong.py (~36 s). Kế hoạch + ma trận truy vết AC: KE-HOACH-KIEM-THU.md · Lỗi: LOI-PHAT-HIEN.md · Chi tiết: PHU-LUC.md

1. "Đúng" nghĩa là gì (Bước 1)

Nhãn → model trả		Vì sao
TRẦN THỊ MAI → Trần Thị Mai	ĐÚNG	hoa/thường là cách trình bày
→ TRAN THI MAI · TRẦN THỊ MAI	SAI	mất dấu hay sai dấu đều là tên người khác
01/03/1990 → 1/3/1990	ĐÚNG	chuẩn hoá về ISO rồi so
000301001234 → 000301001284	SAI	không khớp mờ: lệch 1 chữ số là hồ sơ người khác
15 m² → 15	ĐÚNG	đơn vị do schema quy định

Bất đối xứng nghiêm trọng xử lý bằng trọng số (so_dinh_danh, ho_ten ×3). Vì AC3, phán quyết có 6 giá trị: DUNG, SAI, BO_SOT, TU_CHOI_DUNG (im lặng trên ảnh không đọc được — đúng), BIA (vi phạm AC3), LOI_HE_THONG (không tính điểm). Nhãn: giá trị theo cấu tạo; kỳ vọng hành vi từ lượt đọc lại 33/33 ảnh — chỉ lượt này có quyền phán "ảnh không đọc được"; đồng thuận 105/105. Nói thẳng: annotator

2 là một mô hình ngôn ngữ trong cùng phiên, nên 105/105 là chặn trên, không phải

bằng chứng nhãn đúng (GH-04, đang mờ — số sạch cần hai người gán nhãn mù + kappa). Ba điểm kiểm vào vùng xám (giáp lai đề kín ô giá trị) bị loại khỏi mọi con số. Lượt đọc lại cũng làm nhẹ bớt LOI-01: 3 ảnh CCCD bậc trung bình đọc ra chữ nhưng không rõ dấu thanh, nên quy toàn bộ lỗi dấu cho model là chưa công bằng.

2. Bao phủ đặc tả và kết quả

296 ca tự động (+8 đột biến), không ca nào chạy tay: 38 Gherkin · 47 unit test cho thước đo · 15 đặc tả AC · 13 fitness kiến trúc · 11 đường lỗi adapter · 134 dữ liệu (mỗi ảnh × trường một ca) · 10 hồi quy · 28 nghiệm thu bài nộp. Bao phủ AC: 14/15, toàn bộ ĐẠT; điều khoản còn lại — "hiển thị nổi bật cho người duyệt" — không kiểm được vì giao diện ngoài phạm vi, ghi rõ chữ không bỏ quên.

Chỉ số		Bậc chất lượng ảnh	Điểm tin cậy
Điểm tin cậy (có trọng số)	49,4 %	sạch · nhẹ	66,7 %
Điểm kiểm ĐẠT (không trọng số)	68/129	trung bình	10,3 %
Đúng / trường nghiêm trọng	28,6 %	nặng	0 %
AC3 — từ chối đúng (24 điểm kiểm)	100 %	không đọc được	100 % (đúng)
AC3 — bịa dữ liệu	0 %	lỗi hạ tầng	0

Gãy có một vách: từ bậc trung bình trở đi model gần như ngừng hoạt động. Chữ viết tay 8–27 %, chữ in 20–85 %.

Ở mức hồ sơ con số đôi nghĩa — người dân không cảm nhận accuracy theo trường: trong 27 hồ sơ đọc được chỉ 15 (55,6 %) đi tiếp, 12 (44,4 %) bị trả về — 6 vì bộ tách không neo được trường nào, 4 vì thiếu trường bắt buộc, 2 vì từ chối oan. "41,9 % trường đúng" nghĩa là gần một nửa người dân bị gọi quay lại xã.

3. Lỗi — 3 Nghiêm trọng, 3 Nặng, 1 Trung bình (LOI-PHAT-HIEN.md)

Mã	Lỗi	Mức
LOI-01	Sai dấu họ tên với conf 0,85–0,94 □ lọt cổng HITL: TRẦN→TRẮN, NGUYỄN→NGUYÊN, TUẤN→TUẦN, PHẠM→PHAM, 2 ca mất một phần tên. 6/6 rò rỉ nghiêm trọng đều là họ tên, 4/6 trên ảnh sạch □ siết chất lượng ảnh không vá được. Model tự tin nhất đúng ở chỗ nó sai nguy hiểm nhất.	Nghiêm trọng
LOI-02	Conf trường ô tích là hằng số 0,95 trên cả 7 ca (độ lệch chuẩn 0) — hằng số đội lốt điểm tin cậy; cổng HITL không lọc được gì, đã có 1 ca tick sai ô lọt qua	Nghiêm trọng
LOI-10	44 % hồ sơ người đọc được vẫn bị trả về bắt dân nộp lại	Nghiêm trọng
LOI-03/04/05	Sập từ bậc ảnh trung bình · conf hiệu chuẩn kém (ECE 0,183; khoảng 0,70–0,80 tự báo 0,76 nhưng đúng 0,20) · sai giá trị số trên chữ viết tay (11.000.000→17,000,000, 18,5→18)	Nặng
LOI-06	7 ảnh: OCR ra chữ nhưng bộ tách không neo được trường nào	Trung bình
LOI-07/08/09	Đầu ra thiếu liên kết ảnh gốc, cờ HITL, trạng thái hồ sơ □ vi phạm AC1/AC2/AC3 — do viết ca kiểm thử theo đặc tả tìm ra	đã sửa

Mã	Lỗi	Mức
BD-01...08	8 lỗi trong chính bộ đo : '15 m2' → 152 (unit test bắt), canary hard-code font Windows (CI lộ), sổ nhẵn trùng khoá bị nuốt im lặng, công đếm trang đo bản render khác bản nộp	đã sửa

Quét ngược (bảng đầy đủ PHU-LUC.md §H): ở **0,80** có 6 rò rỉ nghiêm trọng và 46,7 % điểm kiểm tự động qua cổng; phải lên **0,95** mới hết rò rỉ nghiêm trọng, khi đó chỉ còn **26,7 %** tự động. Mẫu số là 105 điểm kiểm phải có giá trị — model im lặng cũng về tay người duyệt y như điểm kiểm bị gán cờ.

4. Kết luận: KHÔNG ĐẠT — chưa dùng được

test_cong_chat_luong_tuyet_doi đang dở, và đó là kết luận chứ không phải test hỏng. Dùng được **nếu đủ cả bốn**: (1) **ngưỡng ≥ 0,95**, họ tên + số định danh + hình thức luôn qua người bắt kể conf — cái giá là chỉ **26,7 %** điểm kiểm được tự động, nên phải trả lời 27 % *có đủ hoàn vốn không* trước khi bàn kỹ thuật; (2) **chặn ảnh ở cửa vào, không ở cửa ra** (việc của UI nộp hồ sơ); (3) **chỉ dùng cho CCCD**; (4) **đối chiếu chéo họ tên + số định danh với CSDL quốc gia về dân cư** — lỗi dấu khôi phục được bằng đối chiếu, không bằng OCR tốt hơn.

Điểm mạnh thật: cụm này **không bịa** — 0/24 điểm kiểm trên ảnh không đọc được, và kiểm thử đột biến cho thấy hành vi đó có **hai lớp phòng vệ độc lập**. so_dinh_danh không một lần trả sai (8 đúng, 7 bỏ sót, **0 sai**). Rủi ro của nó là **im lặng quá mức** □ đội chi phí nhân sự, không phải đưa dữ liệu sai vào hồ sơ.

5. Phép đo này không chứng minh được gì

11 giới hạn được khai thành DỮ LIỆU (gioi_han/so_gioi_han.json), mỗi cái nêu rõ nó chặn chỉ số nào, **cần bằng chứng gì để gỡ**, và hậu quả nếu bỏ qua. Ba cái nặng nhất: giấy tờ **mô phỏng** nên 41,9 % chỉ dùng để so các model trên *cùng bộ ảnh này*; **n = 33** quá nhỏ để kết luận theo từng trường (±20 điểm phần trăm); **cái được đo là cụm OCR + bộ tách của tôi, không phải Tesseract** — 8 lỗi của chính bộ đo đã bị bắt, 3 trong số đó đưa con số từ 32,4 % lên 41,9 %, tức gần một phần tư "lỗi của model" ban đầu là lỗi của người đo. Bộ đo cũng **không đo được chi phí thật** của việc hồ sơ bị trả về, nên *"27 % tự động có đủ hoàn vốn không"* là câu tôi nêu ra chứ không phải câu tôi trả lời được.

Giới hạn **không** nằm dưới dạng đoạn văn cuối báo cáo — chỗ dễ viết cho có rồi quên. features/03-gioi-han-phép-do.feature canh chúng như canh hành vi: công bố chỉ số mà quên khai giới hạn □ **ĐỒ**; khai mà không nói cần bằng chứng gì để gỡ □ **ĐỒ**; tuyên bố đã gỡ mà không dẫn được bằng chứng □ **ĐỒ**. Cổng vừa bắt một lỗ hổng thật: công bố ECE 0,183 và AUC 0,839 mà sổ giới hạn chưa phủ chỉ số hiệu chuẩn (nay là GH-11). GH-10 thì đã được **gỡ** đúng cách — 33/33 ảnh nay đều đã đọc lại, con số không đổi.

Bộ đo còn bị kiểm ngược ba lớp: **47 unit test cho luật so khớp** (bắt BD-05: '15 m2' → 152, lỗi thăm dò không bắt nổi); **8 mutation** □ 7 bị bắt, 1 sống sót đã truy nguyên; và **CI Ubuntu** — dựng CI mới làm lộ BD-06. Cổng hỏi quy **ba tầng**: bắt biến / biên độ $\max(3 \cdot \sigma, 0,05)$, σ **đo được** = 0,0000 / ca cụ thể gọi tên ảnh + trường. 61 điểm kiểm hỏng gán mã lỗi + xfail(strict) nên bộ test **chỉ đỡ khi hành vi đổi**. Thử ngược lang=eng □ 21 điểm kiểm **ĐẠT** → **KHÔNG ĐẠT**.

Trả lời câu hỏi cuối (mục 05)

Không đồng ý với "Model B tốt hơn hẳn, chốt dùng B." Hướng có thể đúng, nhưng bảng đó không đỡ nổi chữ "hẳn", càng không đỡ chữ "chốt".

Bằng chứng mong tới đâu. Mỗi ô là **một lần chạy trên một ảnh**: "đúng 5/5" không phải một tỉ lệ, nó là một lần bốc thăm. Không có lần lặp □ **không biết sigma** □ không tách được model khỏi nhiễu. Ô "B / CCCD ảnh sạch" còn ghi *chưa đo*, nên kết luận dựa trên 2 điều kiện so với 3 — thiếu đúng điều kiện phổ biến nhất ngoài đời. Và chưa thấy nhắc tới **nhãn**: ai quyết "đúng 3/3"? Quyết bằng mắt, không luật viết ra, thì hai người chấm cùng bảng này ra hai kết quả.

Cần thêm gì. ≥ 30 ảnh **có nhãn cho mỗi ô**, điền cả ô đang trống; luật "đúng là gì" viết thành script **trước** khi chạy; chạy **k ≥ 5 lần**/cấu hình, báo trung vị và sigma; tách **lỗi gọi model** khỏi **model đọc không ra** bằng nguyên văn output + tham số gọi + canary mỗi lượt; thời gian báo **p50/p95**; kiểm **hiệu chuẩn conf**, vì hệ thống ở mục 01 lọc bằng conf; kiểm AC3 riêng — model nào bịa thì loại thẳng.

Chỗ bất thường. *Một*: Model A, cùng CCCD, sạch 11,2 s → nhiễu **46,5 s**, gấp **4,15 lần** — cùng model, cùng máy, đó là dấu hiệu của **một đường thực thi khác** (ảnh nhiễu độ phân giải lớn hơn hẳn, retry/timeout im lặng, nhánh dự phòng, hay bị tráo CPU), không phải "khó hơn nên chậm hơn". Truy: chạy lại đúng hai ảnh đó 10 lần, log mốc thời gian **từng giai đoạn** (đọc ảnh → tiền xử lý → suy luận → hậu xử lý) kèm cỡ ảnh sau tiền xử lý. Không lặp lại □ nhiễu môi trường; lặp lại □ gần như chắc là tiền xử lý hoặc cỡ ảnh, tức **lỗi ở cách gọi model**. *Hai*: A **"trả về rỗng"** trên Mẫu 01 — rỗng có hai nghĩa trái ngược: model đọc không ra (theo AC3 là **đúng**), hay lời gọi bị lỗi. Một cái là điểm cộng cho A, cái kia là bug của kỹ sư, mà bảng ghi chung một chữ. Repo này gặp đúng tình huống đó nên phải tách ba cột: *từ chối theo chính sách* (7 ảnh), *đọc ra chữ nhưng không neo được trường* (7 ảnh), *lỗi hạ tầng* (0 ảnh).

Kết luận tôi sẽ viết thay: "B tốt hơn A ở 2/3 điều kiện, mỗi điều kiện 1 ảnh. Chính B chạy Mẫu 01 mất 93,2 s — gấp 6,4 lần khi chạy CCCD — nên phải tính lại chi phí ở mức vài nghìn hồ sơ. Chưa đủ căn cứ để chọn."